

# Iterativne numerične metode v posplošenih linearnih modelih

Mitja Mandić

Mentor: izr. prof. dr. Jaka Smrekar

1. april 2021

# Posplošeni linearni modeli

- Slučajni del, sistematični del, povezovalna funkcija

$$g(\mu) = \eta = x^\top \beta$$

# Posplošeni linearni modeli

- Slučajni del, sistematični del, povezovalna funkcija

$$g(\mu) = \eta = x^\top \beta$$

- Linearna regresija:

$$\mathbb{E}(Y) = \mu = X\beta$$

- Problem - ni najboljša. Rešitev? Transformacija pričakovane vrednosti

# Posplošeni linearni modeli

- Slučajni del, sistematični del, povezovalna funkcija

$$g(\mu) = \eta = x^\top \beta$$

- Linearna regresija:

$$\mathbb{E}(Y) = \mu = X\beta$$

- Problem - ni najboljša. Rešitev? Transformacija pričakovane vrednosti
- Za kategorične podatke  $\rightarrow$  binomska porazdelitev

$$\text{logit}(p_i) = \log\left(\frac{p_i}{1 - p_i}\right) = x_i^T \beta$$

# Točkovno ocenjevanje

- *Cenilka* je funkcija vzorca, s katero ocenjujemo določeno karakteristiko

# Točkovno ocenjevanje

- *Cenilka* je funkcija vzorca, s katero ocenjujemo določeno karakteristiko
- Dve glavni metodi za določanje: metoda momentov in metoda največjega verjetja

# Metoda momentov

- Prvič jo predstavi Čebišev leta 1887
- Enostavnejša za računanje brez računalnika

- Prvič jo predstavi Čebišev leta 1887
- Enostavnejša za računanje brez računalnika
- Karakteristiko izrazimo kot funkcijo momentov  
 $c(X) = g(m_1(X), m_2(X), \dots, m_r(X))$  in jo ocenimo z  $g(\hat{m}_1, \dots, \hat{m}_r)$



# Metoda največjega verjetja

- Najprej privzemimo gostote oblike  $f_X(x; \theta) = f(x; \theta_1, \dots, \theta_r)$  za nek  $\theta \in \Theta$
- Pri fiksni realizaciji poskusa definiramo *funkcijo verjetja*

$$F(X_1, \dots, X_n; \underbrace{\theta_1, \dots, \theta_r}_{\theta}) = f(X_1, \theta) \cdots f(X_n, \theta)$$

- Iščemo  $\theta$ , kjer bo imela maksimum, kar bo natanko ničla odvoda  $\log F$
- Sistemu

$$\frac{\partial}{\partial \theta_j} \log F(X, \theta) = 0$$

pravimo sistem enačb verjetja, njegova rešitev je *cenilka največjega verjetja*

- Niso nujno nepristranske, so pa dosledne, če je rešitev enolična
- Običajno niso eksplicitno rešljive

# Eksponentna družina

$$f_Y(y; \theta, \phi) = \exp \left( \frac{y\theta - b(\theta)}{a(\phi)} + c(y, \phi) \right)$$

za neke  $a(\cdot)$ ,  $b(\cdot)$  in  $c(\cdot)$ ,  $\theta$  pa imenujemo tudi naravni parameter.

# Eksponentna družina

$$f_Y(y; \theta, \phi) = \exp \left( \frac{y\theta - b(\theta)}{a(\phi)} + c(y, \phi) \right)$$

za neke  $a(\cdot)$ ,  $b(\cdot)$  in  $c(\cdot)$ ,  $\theta$  pa imenujemo tudi naravni parameter.  
Označimo z

$$L(y; \theta, \phi) = \log f_Y(y; \theta, \phi) = \frac{y\theta - b(\theta)}{a(\phi)} + c(y, \phi)$$

in njen odvod (funkcijo zbira)

$$\frac{\partial}{\partial \theta} L = \ell(y; \theta, \phi) = \frac{y - b'(\theta)}{a(\phi)}$$

# Eksponentna družina

$$f_Y(y; \theta, \phi) = \exp \left( \frac{y\theta - b(\theta)}{a(\phi)} + c(y, \phi) \right)$$

za neke  $a(\cdot)$ ,  $b(\cdot)$  in  $c(\cdot)$ ,  $\theta$  pa imenujemo tudi naravni parameter.  
Označimo z

$$L(y; \theta, \phi) = \log f_Y(y; \theta, \phi) = \frac{y\theta - b(\theta)}{a(\phi)} + c(y, \phi)$$

in njen odvod (funkcijo zbira)

$$\frac{\partial}{\partial \theta} L = \ell(y; \theta, \phi) = \frac{y - b'(\theta)}{a(\phi)}$$

Iz predavanj STAT1 se spomnimo, da velja

$$\mathbb{E}(\ell) = 0.$$

Na podoben način z uporabo  $\int f_Y(y; \theta) dy = 1$  pa dokažemo tudi  
*informacijsko enakost*

$$\mathbb{E} \left( \frac{\partial^2}{\partial \theta^2} L(\theta) \right) = -\mathbb{E} \left( \left( \frac{\partial}{\partial \theta} L(\theta) \right)^2 \right)$$

Z uporabo prve enakosti sledi

$$\frac{\partial}{\partial \theta} L = \frac{y - b'(\theta)}{a(\phi)} \rightarrow \mu = b'(\theta)a(\phi)$$

Iz druge pa:

$$\begin{aligned}\mathbb{E}\left(\frac{\partial^2}{\partial \theta^2} L\right) &= \mathbb{E}\left(\frac{b''(\theta)}{a(\phi)}\right) = \frac{b''(\theta)}{a(\phi)} \\ \mathbb{E}\left(\left(\frac{\partial}{\partial \theta} L\right)^2\right) &= \frac{1}{a(\phi)^2} \mathbb{E}((y - \mu)^2) = \frac{\text{Var}(Y)}{a(\phi)^2}\end{aligned}$$

od koder direktno sledi

$$\text{Var}(Y) = -b''(\theta)a(\phi)$$

# Zgled z binomsko porazdelitvijo

Naj bo  $Y \sim \text{Bin}(n, p)$  Verjetnost

$$P(Y = y) = \binom{n}{y} p^y (1-p)^{n-y} = \exp \left( y \log \left( \frac{p}{1-p} \right) + n \log(1-p) + \log \binom{n}{y} \right),$$

od koder direktno sledi

$$\theta = \log \frac{p}{1-p} = \log \frac{\mu}{1-\mu}, \quad b(\theta) = \log(1 + e^\theta), \quad \phi = 1, \quad a(\phi) = \frac{\phi}{n},$$

V tem primeru velja torej  $\theta = \text{logit}(\mu) = X^\top \beta = \eta$  in *logit* je kanonična povezovalna funkcija za logistični model. Zakaj je to koristno?

# Obvoz v numerične metode

- Za ocenjevanje parametrov  $\beta$  običajno rešujemo sistem enačb največjega verjetja
- v splošnem ni eksplicitno rešljiv in zato potrebujemo numerične metode

# Obvoz v numerične metode

- Za ocenjevanje parametrov  $\beta$  običajno rešujemo sistem enačb največjega verjetja
- v splošnem ni eksplicitno rešljiv in zato potrebujemo numerične metode
- Newtonova metoda še vedno zelo aktualna zaradi kvadratična konvergence:

$$x_{i+1} = x_i - \frac{f(x_i)}{f'(x_i)}$$

Je pa to metoda za iskanje ničel in ne ekstremov!



# Prilagoditev Newtonove metode

Najprej zapišimo Taylorjev polinom funkcije zbira okoli iskane vrednosti  $\theta$

$$L'(\theta) \approx L'(\theta_0) + L''(\theta_0)(\theta - \theta_0)$$

# Prilagoditev Newtonove metode

Najprej zapišimo Taylorjev polinom funkcije zbira okoli iskane vrednosti  $\theta$

$$L'(\theta) \approx L'(\theta_0) + L''(\theta_0)(\theta - \theta_0)$$

Iščemo ekstrem funkcije, torej ničlo odvoda. Če vstavimo  $\theta = \theta^*$

$$L'(\theta^*) = 0 \approx L'(\theta_0) + L''(\theta_0)(\theta^* - \theta_0)$$

Izrazimo in dobimo iteracijski korak

$$\theta_{t+1} = \theta_t - \frac{L'(\theta_t)}{L''(\theta_t)}$$

# Prilagoditev Newtonove metode

Najprej zapišimo Taylorjev polinom funkcije zbira okoli iskane vrednosti  $\theta$

$$L'(\theta) \approx L'(\theta_0) + L''(\theta_0)(\theta - \theta_0)$$

Iščemo ekstrem funkcije, torej ničlo odvoda. Če vstavimo  $\theta = \theta^*$

$$L'(\theta^*) = 0 \approx L'(\theta_0) + L''(\theta_0)(\theta^* - \theta_0)$$

Izrazimo in dobimo iteracijski korak

$$\theta_{t+1} = \theta_t - \frac{L'(\theta_t)}{L''(\theta_t)}$$

Kaj gre lahko narobe?

# Prilagoditev Newtonove metode

- Invertiranju Hessiana se lahko izognemo z uporabo premikov:

$$\begin{aligned}\theta_{t+1} &= \theta_t + h \\ L''(\theta_t)h &= -L'(\theta_t)\end{aligned}$$

# Prilagoditev Newtonove metode

- Invertiranju Hessiana se lahko izognemo z uporabo premikov:

$$\begin{aligned}\theta_{t+1} &= \theta_t + h \\ L''(\theta_t)h &= -L'(\theta_t)\end{aligned}$$

- Newtonova metoda ni naraščajoč algoritem  $\Rightarrow$  ne vemo ali se bo premikal navzgor ali navzdol

# Prilagoditev Newtonove metode

- Invertiranju Hessiana se lahko izognemo z uporabo premikov:

$$\begin{aligned}\theta_{t+1} &= \theta_t + h \\ L''(\theta_t)h &= -L'(\theta_t)\end{aligned}$$

- Newtonova metoda ni naraščajoč algoritem  $\Rightarrow$  ne vemo ali se bo premikal navzgor ali navzdol
- Če je Hessejeva matrika pozitivno definitna je algoritem konstanten!

# Fisher scoring

Podobno kot Newtonova, z eno ključno razliko:

$$\theta_{i+1} = \theta_i + \frac{L'(\theta_i)}{\mathbb{E}(L''(\theta_i))}$$

# Fisher scoring

Podobno kot Newtonova, z eno ključno razliko:

$$\theta_{i+1} = \theta_i + \frac{L'(\theta_i)}{\mathbb{E}(L''(\theta_i))}$$

Nazaj k eksponentni družini:

$$\log f_y(y; \theta) = L(y; \theta) = \frac{y\theta - b(\theta)}{a(\phi)}$$



$$\frac{\partial L}{\partial \beta_j} = \left(\frac{\partial L}{\partial \theta}\right) \left(\frac{\partial \theta}{\partial \mu}\right) \left(\frac{\partial \mu}{\partial \eta}\right) \left(\frac{\partial \eta}{\partial \beta_j}\right)$$

- $\frac{\partial L}{\partial \theta} = \frac{y - b'(\theta)}{a(\phi)}$

$$\frac{\partial L}{\partial \beta_j} = \left(\frac{\partial L}{\partial \theta}\right) \left(\frac{\partial \theta}{\partial \mu}\right) \left(\frac{\partial \mu}{\partial \eta}\right) \left(\frac{\partial \eta}{\partial \beta_j}\right)$$

- $\frac{\partial L}{\partial \theta} = \frac{y - b'(\theta)}{a(\phi)}$
- Z uporabo  $(b')^{-1}(\mu) = \theta$  dobimo  $\frac{\partial \theta}{\partial \mu} = \frac{1}{b''(\theta)} = \frac{a(\phi)}{\text{var}(Y)}$

$$\frac{\partial L}{\partial \beta_j} = \left(\frac{\partial L}{\partial \theta}\right) \left(\frac{\partial \theta}{\partial \mu}\right) \left(\frac{\partial \mu}{\partial \eta}\right) \left(\frac{\partial \eta}{\partial \beta_j}\right)$$

- $\frac{\partial L}{\partial \theta} = \frac{y - b'(\theta)}{a(\phi)}$
- Z uporabo  $(b')^{-1}(\mu) = \theta$  dobimo  $\frac{\partial \theta}{\partial \mu} = \frac{1}{b''(\theta)} = \frac{a(\phi)}{\text{var}(Y)}$
- $\left(\frac{\partial \mu}{\partial \eta}\right)$  bo odvisen od povezovalne funkcije, s tem se bomo ukvarjali pozneje

$$\frac{\partial L}{\partial \beta_j} = \left(\frac{\partial L}{\partial \theta}\right) \left(\frac{\partial \theta}{\partial \mu}\right) \left(\frac{\partial \mu}{\partial \eta}\right) \left(\frac{\partial \eta}{\partial \beta_j}\right)$$

- $\frac{\partial L}{\partial \theta} = \frac{y - b'(\theta)}{a(\phi)}$
- Z uporabo  $(b')^{-1}(\mu) = \theta$  dobimo  $\frac{\partial \theta}{\partial \mu} = \frac{1}{b''(\theta)} = \frac{a(\phi)}{\text{var}(Y)}$
- $\left(\frac{\partial \mu}{\partial \eta}\right)$  bo odvisen od povezovalne funkcije, s tem se bomo ukvarjali pozneje
- $\left(\frac{\partial \eta}{\partial \beta_j}\right) = x_{ij}$

$$\frac{\partial L}{\partial \beta_j} = \left(\frac{\partial L}{\partial \theta}\right) \left(\frac{\partial \theta}{\partial \mu}\right) \left(\frac{\partial \mu}{\partial \eta}\right) \left(\frac{\partial \eta}{\partial \beta_j}\right)$$

- $\frac{\partial L}{\partial \theta} = \frac{y - b'(\theta)}{a(\phi)}$
- Z uporabo  $(b')^{-1}(\mu) = \theta$  dobimo  $\frac{\partial \theta}{\partial \mu} = \frac{1}{b''(\theta)} = \frac{a(\phi)}{\text{var}(Y)}$
- $\left(\frac{\partial \mu}{\partial \eta}\right)$  bo odvisen od povezovalne funkcije, s tem se bomo ukvarjali pozneje
- $\left(\frac{\partial \eta}{\partial \beta_j}\right) = x_{ij}$

Končno,

$$\frac{\partial L}{\partial \beta_j} = \frac{y - \mu}{\text{var}(Y)} \frac{\partial \mu}{\partial \eta} x_{ij}$$

# Ujemanje F-S in N-R

Če pa uporabimo kanonično povezovalno funkcijo je  $\theta = \eta$  in zato  $\frac{\partial \mu}{\partial \theta} = b''(\theta)$  in funkcija zbira postane

$$\frac{\partial L}{\partial \beta_j} = \frac{y - \mu}{\text{var}(Y)} b''(\theta) x_{ij} = \frac{y - \mu}{a(\phi)} x_{ij}$$

# Ujemanje F-S in N-R

Če pa uporabimo kanonično povezovalno funkcijo je  $\theta = \eta$  in zato  $\frac{\partial \mu}{\partial \theta} = b''(\theta)$  in funkcija zbira postane

$$\frac{\partial L}{\partial \beta_j} = \frac{y - \mu}{\text{var}(Y)} b''(\theta) x_{ij} = \frac{y - \mu}{a(\phi)} x_{ij}$$

Uporabimo  $\mathbb{E}(\frac{\partial^2 L}{\partial \theta^2}) = -\mathbb{E}((\frac{\partial L}{\partial \theta})^2)$  :

$$\begin{aligned} -\mathbb{E}(\frac{\partial^2 L}{\partial \beta_j \partial \beta_k}) &= \mathbb{E}((\frac{\partial L}{\partial \beta_j})(\frac{\partial L}{\partial \beta_k})) \\ &= \mathbb{E}(\frac{y - \mu}{\text{var}(Y)^2})(\frac{\partial \mu}{\partial \eta})^2 x_{ij} x_{ik} \\ &= \frac{1}{\text{var}(Y)} (\frac{\partial \eta}{\partial \mu})^2 x_{ij} x_{ik} \\ &= \frac{b''(\theta)}{a(\phi)} x_{ij} x_{ik} \end{aligned}$$

Po drugi strani pa je odvod funkcije zbira

$$\begin{aligned}\frac{\partial^2 L}{\partial \beta_j \partial \beta_k} &= \frac{\partial}{\partial \beta_k} \left\{ \left( \frac{\partial L}{\partial \theta} \right) \left( \frac{\partial \theta}{\partial \beta_j} \right) \right\} \\ &= \frac{\partial L}{\partial \theta} \left( \frac{\partial^2 \theta}{\partial \beta_j \partial \beta_k} \right) + \left( \frac{\partial \theta}{\partial \beta_j} \right) \left( \frac{\partial^2 L}{\partial \theta^2} \frac{\partial \theta}{\partial \beta_k} \right) \\ &= 0 + \frac{\partial^2 L}{\partial \theta^2} x_{ij} x_{ik},\end{aligned}$$

videli pa smo že da je

$$\frac{\partial^2 L}{\partial \theta^2} = -\frac{b''(\theta)}{a(\phi)}.$$

Sledi torej, da za kanonično povezovalno funkcijo Fisher-scoring algoritem in Newtonova metoda sovpadata!



Še več, iz predavanj se spomnimo da je

$$FI(\theta) = \text{var}\left(\frac{\partial}{\partial \theta} L\right)$$

$\Rightarrow$  Hessejeva matrika je za kanonično povezovalno funkcijo pozitivno definitna in Fisher scoring metoda je naraščajoča!

# Logistični model - teorija v akciji

Spomnimo se:

$$g(\mu) = \text{logit}(p_i) = \theta_i = \eta_i = x_i^\top \beta$$

# Logistični model - teorija v akciji

Spomnimo se:

$$g(\mu) = \text{logit}(p_i) = \theta_i = \eta_i = x_i^\top \beta$$


Imejmo slučajni vektor  $Y = (Y_1, \dots, Y_n)$  z NEP komponentami porazdeljenimi binomsko

$$P(Y_i = y_i) = \binom{m_i}{y_i} p_i^{y_i} (1 - p_i)^{m_i - y_i}$$

Funkcija verjetja se glasi:

$$\begin{aligned} L(p_i) &= \log \left\{ \prod_{i=1}^n p_i^{y_i} (1 - p_i)^{m_i - y_i} \right\} \\ &= \sum_{i=1}^n \{ y_i \log p_i + (m_i - y_i) \log(1 - p_i) \} \\ &= \sum_{i=1}^n \left\{ m_i \log(1 - p_i) + y_i \log \left( \frac{p_i}{1 - p_i} \right) \right\} \end{aligned}$$

$$p = \frac{e^{x^T \beta}}{1 + e^{x^T \beta}}$$



# Enačbe verjetja v logističnem modelu

Upoštevamo še  $\log \frac{p_i}{1-p_i} = x_i^\top \beta$  in dobimo

$$L(\beta) = \sum_{i=1}^n (y_i(x_i^\top \beta) - m_i \log(1 + \exp x_i^\top \beta))$$

Od tu vidimo, da je res odvisna le od parametra  $\beta$

# Enačbe verjetja v logističnem modelu

Sedaj potrebujemo še odvode.

$$\begin{aligned}\frac{\partial}{\partial \beta_j} (x_i^\top \beta) &= \frac{\partial}{\partial \beta_j} (\beta_0 + x_{i1}\beta_1 + \dots x_{ir}\beta_r) \\ &= x_{ij} \\ \frac{\partial}{\partial \beta_j} \log(1 + \exp(x_i^\top \beta)) &= \frac{\frac{\partial}{\partial \beta_j} \exp(x_i^\top \beta)}{1 + \exp(x_i^\top \beta)} \\ &= \frac{\exp(x_i^\top \beta)}{1 + \exp(x_i^\top \beta)} \frac{\partial}{\partial \beta_j} (x_i^\top \beta) \\ &= p_i(\beta) x_{ij},\end{aligned}$$

kjer smo upoštevali  $p_i = \frac{\exp x_i^\top \beta}{1 + \exp x_i^\top \beta}$ .

# Enačbe verjetja v logističnem modelu

Sedaj potrebujemo še odvode.

$$\begin{aligned}\frac{\partial}{\partial \beta_j} (x_i^\top \beta) &= \frac{\partial}{\partial \beta_j} (\beta_0 + x_{i1}\beta_1 + \dots x_{ir}\beta_r) \\ &= x_{ij} \\ \frac{\partial}{\partial \beta_j} \log(1 + \exp(x_i^\top \beta)) &= \frac{\frac{\partial}{\partial \beta_j} \exp(x_i^\top \beta)}{1 + \exp(x_i^\top \beta)} \\ &= \frac{\exp(x_i^\top \beta)}{1 + \exp(x_i^\top \beta)} \frac{\partial}{\partial \beta_j} (x_i^\top \beta) \\ &= p_i(\beta) x_{ij},\end{aligned}$$

kjer smo upoštevali  $p_i = \frac{\exp x_i^\top \beta}{1 + \exp x_i^\top \beta}$ . Iščemo torej ničlo

$$\frac{\partial}{\partial \beta_j} L(\beta) = \sum_{i=1}^n (x_{ij}(y_i - m_i p_i(\beta)))$$

za  $j = 0, \dots, r$

# Enačbe verjetja v logističnem modelu

Za uporabo Newtonove metode bomo potrebovali še drugi odvod, za kar moramo izračunati še

$$\begin{aligned}\frac{\partial p_i(\beta)}{\partial \beta_k} &= \frac{\partial}{\partial \beta_k} \frac{\exp x_i^\top \beta}{1 + \exp x_i^\top \beta} \\ &= x_{ik} p_i(\beta) (1 - p_i(\beta))\end{aligned}$$

in sestaviti to v

$$\frac{\partial^2}{\partial \beta_j \partial \beta_k} L(\beta) = - \sum_i^n (x_{ij} x_{ik} m_i p_i(\beta) (1 - p_i(\beta)))$$

za  $j, k = 0, 1, \dots, r$ , kar pa lahko poenostavimo v

$$\ddot{L}(\beta) = - \sum_{i=1}^n (x_{ij} x_{ik} v_i(\beta))$$



# Enačbe verjetja v logističnem modelu

Preglednejši in priročnejši je zapis v matrični obliki:

$$L(\beta) = \mathbf{y}^\top \mathbf{X}\beta - m^\top \log(1 + \exp \mathbf{X}\beta)$$

$$\dot{L}(\beta) = \mathbf{X}^\top (\mathbf{y} - m \circ p(\beta)) = \mathbf{X}^\top (\mathbf{y} - m \circ p(\beta)) = \mathbf{X}^\top (\mathbf{y} - \mu(\beta))$$

Za drugi odvod definirajmo diagonalno matriko

$v(\beta) = \text{diag}\{m_1 p_1 (1 - p_1), \dots, m_n p_n (1 - p_n)\}$  in povzemimo

$$\ddot{L}(\beta) = -\mathbf{X}^\top v(\beta) \mathbf{X}$$

# Fisher scoring za logistični model

$$\begin{aligned}\hat{\beta}_{i+1} &= \hat{\beta}_i + (X^T v(\hat{\beta}_i) X)^{-1} X^T (y - \mu(\hat{\beta}_i)) \\ &= \hat{\beta}_i + (\text{inverz info})(\text{score})\end{aligned}$$

# Fisher scoring za logistični model

$$\begin{aligned}\hat{\beta}_{i+1} &= \hat{\beta}_i + (X^T v(\hat{\beta}_i) X)^{-1} X^T (y - \mu(\hat{\beta}_i)) \\ &= \hat{\beta}_i + (\text{inverz info})(\text{score})\end{aligned}$$

Računanju inverza se izognemo z uvedbo premikov:

$$\begin{aligned}h &= \hat{\beta}_{i+1} - \hat{\beta}_i \\ X^T v(\hat{\beta}_i) X &= h * X^T (y - \mu(\hat{\beta}_i))\end{aligned}$$

---

**function** oceniParametre(iteracije, X, Y,  $\beta_{\text{zacetni}}$ ,  $\epsilon$ )

---

$$p = \frac{\exp(X^\top \beta_{\text{star}})}{1 + \exp(X^\top \beta_{\text{star}})}$$

$$V = p(1 - p)$$

$$\text{Score} = X^\top (Y - p)$$

$$\text{Info} = X^\top V X$$

**Reši sistem na h:**  $\text{Info} * h = \text{Score}$

$$\beta_{\text{star}} = \beta_{\text{zacetni}}$$

$$\beta_{\text{nov}} = \beta_{\text{star}} + h$$

**while**  $i \leq \text{iteracije}$  **do**

**if**  $\beta_{\text{nov}} - \beta_{\text{star}} \geq \epsilon$  **then**

$$p = \frac{\exp(X^\top \beta_{\text{nov}})}{1 + \exp(X^\top \beta_{\text{nov}})}$$

$$V = p(1 - p)$$

$$\text{Score} = X^\top (Y - p)$$

$$\text{Info} = X^\top V X$$

**Razreši na h:**  $\text{Info} * h = \text{Score}$

$$\beta_{\text{star}} = \beta_{\text{nov}}$$

$$\beta_{\text{nov}} = \beta_{\text{star}} + h$$

**else**

*Dosegli smo željeno natančnost v zadostnem številu korakov*

**return**  $\beta_{\text{nov}}$

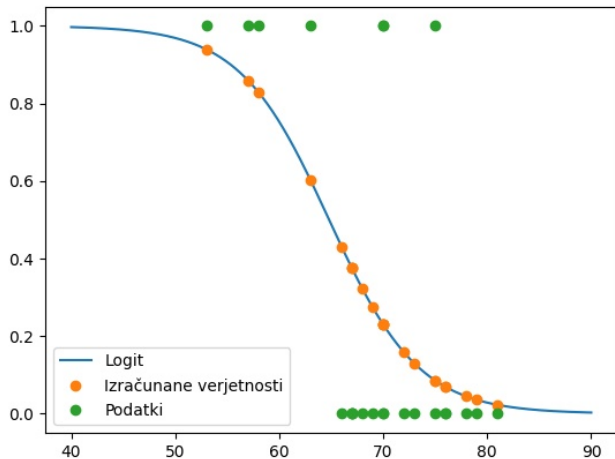
**end if**

**end while**

---

# Challenger podatki

$$p = \frac{e^{15.04290 - 0.23216x}}{1 + e^{15.04290 - 0.23216x}}$$



# Kaj še bom naredil

- Ne-kanonični modeli (npr. *probit* za direktno primerjavo)
- Razširitev numeričnega dela