

Iterativne numerične metode v posplošenih linearnih modelih

Mitja Mandić

Mentor: izr. prof. dr. Jaka Smrekar

9. september 2021

Eksponentna družina

- Porazdelitev pripada enoparametrični eksponentni družini z disperzijskim parametrom, če ima gostoto oblike

$$f_Y(y; \theta, \phi) = \exp \left(\frac{y\theta - b(\theta)}{a(\phi)} + c(y, \phi) \right),$$

θ imenujemo *naravni* ali *kanonični* parameter, ϕ pa *disperzijski* parameter

Eksponentna družina

- Porazdelitev pripada enoparametrični eksponentni družini z disperzijskim parametrom, če ima gostoto oblike

$$f_Y(y; \theta, \phi) = \exp \left(\frac{y\theta - b(\theta)}{a(\phi)} + c(y, \phi) \right),$$

θ imenujemo *naravni* ali *kanonični* parameter, ϕ pa *disperzijski* parameter

- Velja $\mathbb{E}(Y) = b'(\theta)$ in $\text{Var}(Y) = b''(\theta)a(\phi)$

Eksponentna družina

- Porazdelitev pripada enoparametrični eksponentni družini z disperzijskim parametrom, če ima gostoto oblike

$$f_Y(y; \theta, \phi) = \exp \left(\frac{y\theta - b(\theta)}{a(\phi)} + c(y, \phi) \right),$$

θ imenujemo *naravni* ali *kanonični* parameter, ϕ pa *disperzijski* parameter

- Velja $\mathbb{E}(Y) = b'(\theta)$ in $\text{Var}(Y) = b''(\theta)a(\phi)$
- Za $Y \sim N(\mu, \sigma^2)$ z gostoto $\frac{1}{\sqrt{2\pi\sigma^2}} \exp \left(-\frac{(y-\mu)^2}{2\sigma^2} \right)$ izrazimo

$$\theta = \mu, \quad \phi = \sigma^2, \quad a(\sigma^2) = \sigma^2, \quad b(\mu) = \frac{\mu^2}{2}$$

Eksponentna družina

- Porazdelitev pripada enoparametrični eksponentni družini z disperzijskim parametrom, če ima gostoto oblike

$$f_Y(y; \theta, \phi) = \exp \left(\frac{y\theta - b(\theta)}{a(\phi)} + c(y, \phi) \right),$$

θ imenujemo *naravni* ali *kanonični* parameter, ϕ pa *disperzijski* parameter

- Velja $\mathbb{E}(Y) = b'(\theta)$ in $\text{Var}(Y) = b''(\theta)a(\phi)$
- Za $Y \sim N(\mu, \sigma^2)$ z gostoto $\frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(y-\mu)^2}{2\sigma^2}\right)$ izrazimo

$$\theta = \mu, \phi = \sigma^2, a(\sigma^2) = \sigma^2, b(\mu) = \frac{\mu^2}{2}$$

- Za $Y \sim \text{Bin}(m, p)$ je $P(Y = y) = \binom{m}{y} p^y (1-p)^{m-y}$, kar preoblikujemo v

$$\exp \left(y \log \left(\frac{p}{1-p} \right) + m \log(1-p) + \log \binom{m}{y} \right)$$

in preberemo $\theta = \log \frac{p}{1-p}$, $b(\theta) = m \log(1 + e^\theta)$, $a(\phi) = 1$.

Posplošeni linearni modeli

Vsak posplošeni linearni model sestavljajo trije deli:

- slučajni del – porazdelitev proučevane slučajne spremenljivke

Posplošeni linearni modeli

Vsak posplošeni linearni model sestavljajo trije deli:

- **slučajni del** – porazdelitev proučevane slučajne spremenljivke
- **sistematični del** – linearna relacija med pojasnjevalnimi spremenljivkami

Posplošeni linearni modeli

Vsak posplošeni linearni model sestavljajo trije deli:

- **slučajni del** – porazdelitev proučevane slučajne spremenljivke
- **sistematični del** – linearna relacija med pojasnjevalnimi spremenljivkami
- **povezovalna funkcija** – povezava med sistematičnim delom in pričakovano vrednostjo. Če je enaka naravnemu parametru porazdelitve ji rečemo *kanonična* povezovalna funkcija

Posplošeni linearni modeli

Vsak posplošeni linearni model sestavljajo trije deli:

- **slučajni del** – porazdelitev proučevane slučajne spremenljivke
- **sistematični del** – linearna relacija med pojasnjevalnimi spremenljivkami
- **povezovalna funkcija** – povezava med sistematičnim delom in pričakovano vrednostjo. Če je enaka naravnemu parametru porazdelitve ji rečemo *kanonična* povezovalna funkcija

Skupaj:

$$g(\mu) = X\beta$$

Logistični model

- Predpostavimo binomsko porazdelitev Y . Uporablja se za računanje verjetnosti iz binarnih podatkov, model je oblike

$$\text{logit}(p) = \log \left(\frac{p}{1-p} \right) = X\beta$$


Logistični model

- Predpostavimo binomsko porazdelitev Y . Uporablja se za računanje verjetnosti iz binarnih podatkov, model je oblike

$$\text{logit}(p) = \log\left(\frac{p}{1-p}\right) = X\beta$$

- Izrazimo

$$p_i = \frac{\exp(x_i^\top \beta)}{1 + \exp(x_i^\top \beta)}$$



Logistični model

- Predpostavimo binomsko porazdelitev Y . Uporablja se za računanje verjetnosti iz binarnih podatkov, model je oblike

$$\text{logit}(p) = \log\left(\frac{p}{1-p}\right) = X\beta$$

- Izrazimo

$$p_i = \frac{\exp(x_i^\top \beta)}{1 + \exp(x_i^\top \beta)}$$

- Logaritemska funkcija verjetja, funkcija zbira in njen odvod

$$\ell(\beta) = \sum_{i=1}^n (y_i(x_i^\top \beta) - m_i \log(1 + \exp(x_i^\top \beta)))$$

$$\frac{\partial}{\partial \beta_j} \ell(\beta) = \sum_{i=1}^n (x_{ij}(y_i - \mu_i)), \quad j = 0, \dots, r$$

$$\frac{\partial^2}{\partial \beta_j \partial \beta_k} \ell(\beta) = - \sum_{i=1}^n (x_{ij} v_i(\beta) x_{ik}), \quad j, k = 0, \dots, r$$

Probit model

$$p = \Phi(X\beta)$$

- Razvit v enake namene kot logistični model, znova se za Y predpostavi binomsko porazdelitev
- Vidimo, da povezovalna funkcija $\Phi^{-1}(p)$ ni kanonična

Probit model

$$p = \Phi(X\beta)$$

- Razvit v enake namene kot logistični model, znova se za Y predpostavi binomsko porazdelitev
- Vidimo, da povezovalna funkcija $\Phi^{-1}(p)$ ni kanonična
- Logaritemska funkcija verjetja, funkcija zbira in njen odvod

$$\ell(\beta) = \sum_{i=1}^n (y_i \log \Phi(x_i^\top \beta) + (m_i - y_i) \log(1 - \Phi(x_i^\top \beta)))$$

$$\frac{\partial}{\partial \beta_j} \ell(\beta) = \sum_{i=1}^n \frac{y - m_i \Phi(x_i^\top \beta)}{\Phi(x_i^\top \beta)(1 - \Phi(x_i^\top \beta))} \phi(x_i^\top \beta) x_{ij}, \quad j = 0, \dots, r$$

$$\begin{aligned} \frac{\partial^2}{\partial \beta_j \partial \beta_k} \ell(\beta) = & \sum_{i=1}^n x_{ij} \frac{(y_i - m_i \Phi(x_i^\top \beta))(-\phi(x_i^\top \beta)x_i^\top \beta) - m_i \phi(x_i^\top \beta)^2}{\Phi(x_i^\top \beta)(1 - \Phi(x_i^\top \beta))} x_{ik} - \\ & - x_{ij} \frac{\phi(x_i^\top \beta)^2(1 - 2\Phi(x_i^\top \beta))}{(\Phi(x_i^\top \beta)(1 - \Phi(x_i^\top \beta)))^2} x_{ik}, \quad j, k = 0, \dots, r \end{aligned}$$

Metoda največjega verjetja

- Najprej privzemimo gostote oblike $f_X(x; \theta) = f(x; \theta_1, \dots, \theta_r)$ za nek $\theta \in \Theta^r$
- Pri fiksni realizaciji poskusa definiramo *funkcijo verjetja*

$$F(X_1, \dots, X_n; \underbrace{\theta_1, \dots, \theta_r}_{\theta}) = f(X_1, \theta) \cdots f(X_n, \theta)$$

- Iščemo njen maksimum, kar bo hkrati tudi maksimum $\log(F)$

Metoda največjega verjetja

- Najprej privzemimo gostote oblike $f_X(x; \theta) = f(x; \theta_1, \dots, \theta_r)$ za nek $\theta \in \Theta^r$
- Pri fiksni realizaciji poskusa definiramo *funkcijo verjetja*

$$F(X_1, \dots, X_n; \underbrace{\theta_1, \dots, \theta_r}_{\theta}) = f(X_1, \theta) \cdots f(X_n, \theta)$$

- Iščemo njen maksimum, kar bo hkrati tudi maksimum $\log(F)$
- Sistemu

$$\frac{\partial}{\partial \theta_j} \log F(X, \theta) = 0, \quad j = 1, \dots, r$$

pravimo sistem enačb verjetja, njegova rešitev je kandidatka za *cenilko največjega verjetja*

Metoda največjega verjetja

- Najprej privzemimo gostote oblike $f_X(x; \theta) = f(x; \theta_1, \dots, \theta_r)$ za nek $\theta \in \Theta^r$
- Pri fiksni realizaciji poskusa definiramo *funkcijo verjetja*

$$F(X_1, \dots, X_n; \underbrace{\theta_1, \dots, \theta_r}_{\theta}) = f(X_1, \theta) \cdots f(X_n, \theta)$$


- Iščemo njen maksimum, kar bo hkrati tudi maksimum $\log(F)$
- Sistemu

$$\frac{\partial}{\partial \theta_j} \log F(X, \theta) = 0, \quad j = 1, \dots, r$$

pravimo sistem enačb verjetja, njegova rešitev je kandidatka za *cenilko največjega verjetja*


- Niso nujno nepristranske, so pa dosledne, če je rešitev enolična
- **Običajno niso eksplicitno rešljive**

Obstoj cenilke največjega verjetja v logističnem modelu




Slika: Popolna separacija. Rešitev ne obstaja


Obstoj cenilke največjega verjetja v logističnem modelu



Slika: Popolna separacija. Rešitev ne obstaja




Slika: Nepopolna separacija, drugi primer. Rešitev ne obstaja




Slika: Nepopolna separacija, prvi primer. Rešitev ne obstaja


Obstoj cenilke največjega verjetja v logističnem modelu




Slika: Popolna separacija. Rešitev ne obstaja



Slika: Nepopolna separacija, prvi primer. Rešitev ne obstaja



Slika: Nepopolna separacija, drugi primer. Rešitev ne obstaja



Slika: Prekrivanje. Rešitev obstaja in je enolična

Numerične metode

- Iterativne metode, ki temeljijo na Newtonovi metodi za iskanje ničel funkcije

$$x_{i+1} = x_i - \frac{f(x_i)}{f'(x_i)}$$

Numerične metode

- Iterativne metode, ki temeljijo na Newtonovi metodi za iskanje ničel funkcije

$$x_{i+1} = x_i - \frac{f(x_i)}{f'(x_i)}$$

- Za iskanje ekstremov logaritemske funkcije verjetja metodo prilagodimo. Enačimo gradient $\ell(\theta)$ z nič in dobimo

$$\theta_{i+1} = \theta_i - \left(\frac{\partial^2}{\partial \theta^2} \ell(\theta_i) \right)^{-1} \frac{\partial}{\partial \theta} \ell(\theta_i).$$

Računanje in invertiranje Hessiana pa je lahko problematično. Kako se temu izognemo?

Numerične metode

- Iterativne metode, ki temeljijo na Newtonovi metodi za iskanje ničel funkcije

$$x_{i+1} = x_i - \frac{f(x_i)}{f'(x_i)}$$

- Za iskanje ekstremov logaritemske funkcije verjetja metodo prilagodimo. Enačimo gradient $\ell(\theta)$ z nič in dobimo

$$\theta_{i+1} = \theta_i - \left(\frac{\partial^2}{\partial \theta^2} \ell(\theta_i) \right)^{-1} \frac{\partial}{\partial \theta} \ell(\theta_i).$$

Računanje in invertiranje Hessiana pa je lahko problematično. Kako se temu izognemo?

- Namesto inverza uvedemo računanje premikov. Iteracijski korak je tako

$$\begin{aligned} \left(\frac{\partial^2}{\partial \theta^2} \ell(\theta_i) \right) h &= - \frac{\partial}{\partial \theta} \ell(\theta_i) \\ \theta_{i+1} &= \theta_i + h \end{aligned}$$

Fisherjeva zbirna metoda

$$\theta_{i+1} = \theta_i + \text{FI}(\theta_i)^{-1} \left(\frac{\partial}{\partial \theta} \ell(\theta_i) \right),$$

kjer je $\text{FI}(\theta) = \mathbb{E} \left(\left(\frac{\partial}{\partial \theta} \ell \right) \left(\frac{\partial}{\partial \theta} \ell \right)^\top \right)$.

Fisherjeva zbirna metoda

$$\theta_{i+1} = \theta_i + \text{FI}(\theta_i)^{-1} \left(\frac{\partial}{\partial \theta} \ell(\theta_i) \right),$$

kjer je $\text{FI}(\theta) = \mathbb{E} \left(\left(\frac{\partial}{\partial \theta} \ell \right) \left(\frac{\partial}{\partial \theta} \ell \right)^\top \right)$. *Informacijska enakost* pravi

$$\text{FI}(\theta) = \mathbb{E} \left(\left(\frac{\partial}{\partial \theta} \ell \right) \left(\frac{\partial}{\partial \theta} \ell \right)^\top \right) = -\mathbb{E} \left(\frac{\partial^2}{\partial \theta^2} \ell \right),$$

Fisherjeva zbirna metoda

$$\theta_{i+1} = \theta_i + \text{FI}(\theta_i)^{-1} \left(\frac{\partial}{\partial \theta} \ell(\theta_i) \right),$$

kjer je $\text{FI}(\theta) = \mathbb{E} \left(\left(\frac{\partial}{\partial \theta} \ell \right) \left(\frac{\partial}{\partial \theta} \ell \right)^\top \right)$. *Informacijska enakost* pravi

$$\text{FI}(\theta) = \mathbb{E} \left(\left(\frac{\partial}{\partial \theta} \ell \right) \left(\frac{\partial}{\partial \theta} \ell \right)^\top \right) = -\mathbb{E} \left(\frac{\partial^2}{\partial \theta^2} \ell \right),$$

V nalogi smo za kanonične povezovalne funkcije dokazali

$$\mathbb{E} \left(\frac{\partial^2}{\partial \theta^2} \ell \right) = \frac{\partial^2}{\partial \theta^2} \ell$$

in sledi

$$\text{FI}(\theta) = -\frac{\partial^2}{\partial \theta^2} \ell$$

Fisherjeva zbirna metoda

$$\theta_{i+1} = \theta_i + \text{FI}(\theta_i)^{-1} \left(\frac{\partial}{\partial \theta} \ell(\theta_i) \right),$$

kjer je $\text{FI}(\theta) = \mathbb{E} \left(\left(\frac{\partial}{\partial \theta} \ell \right) \left(\frac{\partial}{\partial \theta} \ell \right)^\top \right)$. Informacijska enakost pravi

$$\text{FI}(\theta) = \mathbb{E} \left(\left(\frac{\partial}{\partial \theta} \ell \right) \left(\frac{\partial}{\partial \theta} \ell \right)^\top \right) = -\mathbb{E} \left(\frac{\partial^2}{\partial \theta^2} \ell \right),$$

V nalogi smo za kanonične povezovalne funkcije dokazali

$$\mathbb{E} \left(\frac{\partial^2}{\partial \theta^2} \ell \right) = \frac{\partial^2}{\partial \theta^2} \ell$$

in sledi

$$\text{FI}(\theta) = -\frac{\partial^2}{\partial \theta^2} \ell$$

→ za kanonične povezovalne funkcije Fisherjeva zbirna metoda in Newtonov algoritem sovpadata!

Fisherjeva zbirna metoda

Velja še:

$$-\frac{\partial^2}{\partial \theta^2} \ell = \text{FI}(\theta) = \text{Var} \left(\frac{\partial}{\partial \theta} \ell \right),$$

torej je Hessejeva matrika log-verjetja negativno semidefinitna.

Fisherjeva zbirna metoda

Velja še:

$$-\frac{\partial^2}{\partial \theta^2} \ell = \text{FI}(\theta) = \text{Var} \left(\frac{\partial}{\partial \theta} \ell \right),$$

torej je Hessejeva matrika log-verjetja negativno semidefinitna.

Taylorjev polinom za funkcijo zbira (ob upoštevanju $\frac{\partial}{\partial \theta} \ell(\theta^*) = 0$) je

$$\ell(\theta^* + s) = \ell(\theta^*) + \frac{1}{2} s^\top \frac{\partial^2}{\partial \theta^2} \ell(\theta^*) s.$$

Fisherjeva zbirna metoda

Velja še:

$$-\frac{\partial^2}{\partial \theta^2} \ell = \text{FI}(\theta) = \text{Var} \left(\frac{\partial}{\partial \theta} \ell \right),$$

torej je Hessejeva matrika log-verjetja negativno semidefinitna.

Taylorjev polinom za funkcijo zbira (ob upoštevanju $\frac{\partial}{\partial \theta} \ell(\theta^*) = 0$) je

$$\ell(\theta^* + s) = \ell(\theta^*) + \frac{1}{2} s^\top \frac{\partial^2}{\partial \theta^2} \ell(\theta^*) s.$$

⇒ imamo konveksen optimizacijski problem

⇒ reševanje sistema enačb za premik je enostavnejše

Iteracijski korak logističnega modela:

$$\underbrace{(X^\top v(\hat{\beta}_i) X)}_{\text{Fisher info}} h = \underbrace{X^\top (y - \mu(\hat{\beta}_i))}_{\text{funkcija zbira}}$$

$$\hat{\beta}_{i+1} = \hat{\beta}_i + h$$

function očniParametre(iteracije, X, Y, β_{zacetni} , ϵ)

$$p = \frac{\exp(X^\top \beta_{\text{star}})}{1 + \exp(X^\top \beta_{\text{star}})}$$

$$V = p(1 - p)$$

$$\text{Score} = X^\top (Y - p)$$

$$\text{Info} = X^\top V X$$

Reši sistem na h: $\text{Info} * h = \text{Score}$

$$\beta_{\text{star}} = \beta_{\text{zacetni}}$$

$$\beta_{\text{nov}} = \beta_{\text{star}} + h$$

while $i \leq \text{iteracije}$ **do**

if $\beta_{\text{nov}} - \beta_{\text{star}} \geq \epsilon$ **then**

$$p = \frac{\exp(X^\top \beta_{\text{nov}})}{1 + \exp(X^\top \beta_{\text{nov}})}$$

$$V = p(1 - p)$$

$$\text{Score} = X^\top (Y - p)$$

$$\text{Info} = X^\top V X$$

Razreši na h: $\text{Info} * h = \text{Score}$

$$\beta_{\text{star}} = \beta_{\text{nov}}$$

$$\beta_{\text{nov}} = \beta_{\text{star}} + h$$

else

Dosegli smo želeno natančnost v zadostnem številu korakov

return β_{nov}


end if

end while

Rezultati

Iz interneta smo pridobili podatke o odpovedi tesnil iz vesoljskih poletov pred dobo *Challengerja* in izračunali:


- verjetnost odpovedi z logistično regresijo le s podatki o temperaturi



Rezultati

Iz interneta smo pridobili podatke o odpovedi tesnil iz vesoljskih poletov pred dobo *Challengerja* in izračunali:


- verjetnost odpovedi z logistično regresijo le s podatki o temperaturi
- verjetnost odpovedi s temperaturo in pritiskom



Rezultati

Iz interneta smo pridobili podatke o odpovedi tesnil iz vesoljskih poletov pred dobo *Challengerja* in izračunali:

- verjetnost odpovedi z logistično regresijo le s podatki o temperaturi
- verjetnost odpovedi s temperaturo in pritiskom
- primerjava logistične in probit regresije le s podatki o temperaturi



- Želeli smo bolje razumeti ozadje računanja parametrov v posplošenih linearnih modelih
- Za logistični model smo izpeljali enačbe verjetja in raziskali kdaj rešitve obstajajo
- Formule smo posplošili za vse modele s porazdelitvami iz eksponentne družine in videli prednosti uporabe kanoničnih povezovalnih funkcij
- Newtonovo metodo smo prilagodili za iskanje ekstremov in dokazali njeno sovpadanje z Fisherjevo zbirno metodo za kanonične modele
- Vso teorijo smo na koncu povezali v praktičnih primerih



A. Agresti.

An introduction to categorical data analysis.

John Wiley & Sons, 2007.



A. Albert and J. A. Anderson.

On the existence of maximum likelihood estimates in logistic regression models.

Biometrika, 71(1):1–10, 1984.



E. B. Erhard.

Logistic regression and Newton-Raphson.

https://statacumen.com/teach/SC1/SC1_11_LogisticRegression.pdf.



K. Lange.

Numerical analysis for statisticians.

Springer Science & Business Media, 2010.

Literatura II



P. McCullagh and J. Nelder.

Generalized linear models.

Springer US, 1989.



B. Plestenjak.

Numerične metode.

https://www.fmf.uni-lj.si/~kozak/PedagoskoDelo/Gradiva/NumericneMetodeI_praktiki/Skripta/BorPlestenjakKnjigaNM.pdf, 2010.



G. Rodríguez.

Lecture notes on Generalized Linear Models.

<https://data.princeton.edu/wws509/notes/>, 2007.