

Iterativne numerične metode v posplošenih linearnih modelih

Mitja Mandić

Mentor: izr. prof. dr. Jaka Smrekar

5. september 2021

Eksponentna družina

- Porazdelitev pripada enoparametrični eksponentni družini z disperzijskim parametrom, če ima gostoto oblike

$$f_Y(y; \theta, \phi) = \exp \left(\frac{y\theta - b(\theta)}{a(\phi)} + c(y, \phi) \right),$$

za neke funkcije $a(\cdot)$, $b(\cdot)$ in $c(\cdot)$. Parametru θ pravimo *kanonični* oziroma *naravni* parameter, ϕ pa imenujemo *disperzijski parameter*

- Velja $\mathbb{E}(Y) = b'(\theta)$ in $\text{Var}(Y) = b''(\theta)a(\phi)$

Eksponentna družina

- Porazdelitev pripada enoparametrični eksponentni družini z disperzijskim parametrom, če ima gostoto oblike

$$f_Y(y; \theta, \phi) = \exp \left(\frac{y\theta - b(\theta)}{a(\phi)} + c(y, \phi) \right),$$

za neke funkcije $a(\cdot)$, $b(\cdot)$ in $c(\cdot)$. Parametru θ pravimo *kanonični* oziroma *naravni* parameter, ϕ pa imenujemo *disperzijski parameter*

- Velja $\mathbb{E}(Y) = b'(\theta)$ in $\text{Var}(Y) = b''(\theta)a(\phi)$
- Za $Y \sim N(\mu, \sigma^2)$ z gostoto $\frac{1}{\sqrt{2\pi\sigma^2}} \exp -\frac{(y-\mu)^2}{2\sigma^2}$ izrazimo

$$\theta = \mu, \phi = \sigma^2, a(\sigma^2) = \sigma^2, b(\mu) = \frac{\mu^2}{2}$$

Eksponentna družina

- Porazdelitev pripada enoparametrični eksponentni družini z disperzijskim parametrom, če ima gostoto oblike

$$f_Y(y; \theta, \phi) = \exp \left(\frac{y\theta - b(\theta)}{a(\phi)} + c(y, \phi) \right),$$

za neke funkcije $a(\cdot)$, $b(\cdot)$ in $c(\cdot)$. Parametru θ pravimo *kanonični* oziroma *naravni* parameter, ϕ pa imenujemo *disperzijski parameter*

- Velja $\mathbb{E}(Y) = b'(\theta)$ in $\text{Var}(Y) = b''(\theta)a(\phi)$
- Za $Y \sim N(\mu, \sigma^2)$ z gostoto $\frac{1}{\sqrt{2\pi\sigma^2}} \exp -\frac{(y-\mu)^2}{2\sigma^2}$ izrazimo

$$\theta = \mu, \phi = \sigma^2, a(\sigma^2) = \sigma^2, b(\mu) = \frac{\mu^2}{2}$$

- Za $Y \sim \text{Bin}(m, p)$ je $P(Y = y) = \binom{m}{y} p^y (1-p)^{m-y}$, kar preoblikujemo v

$$\exp \left(y \log \left(\frac{p}{1-p} \right) + m \log(1-p) + \log \binom{m}{y} \right)$$

in preberemo $\theta = \log \frac{p}{1-p}$, $b(\theta) = m \log(1 + e^\theta)$, $a(\phi) = 1$.

Posplošeni linearni modeli

Vsak posplošeni linearni model sestavljajo trije deli:

- slučajni del – porazdelitev proučevane slučajne spremenljivke

Posplošeni linearni modeli

Vsak posplošeni linearni model sestavljajo trije deli:

- **slučajni del** – porazdelitev proučevane slučajne spremenljivke
- **sistematični del** – linearna relacija med pojasnjevalnimi spremenljivkami

Posplošeni linearni modeli

Vsak posplošeni linearni model sestavljajo trije deli:

- **slučajni del** – porazdelitev proučevane slučajne spremenljivke
- **sistematični del** – linearna relacija med pojasnjevalnimi spremenljivkami
- **povezovalna funkcija** – povezava med sistematičnim delom in pričakovano vrednostjo. Če je enaka naravnemu parametru porazdelitve ji rečemo *kanonična* povezovalna funkcija

Posplošeni linearni modeli

Vsak posplošeni linearni model sestavljajo trije deli:

- **slučajni del** – porazdelitev proučevane slučajne spremenljivke
- **sistematični del** – linearna relacija med pojasnjevalnimi spremenljivkami
- **povezovalna funkcija** – povezava med sistematičnim delom in pričakovano vrednostjo. Če je enaka naravnemu parametru porazdelitve ji rečemo *kanonična* povezovalna funkcija

Skupaj:

$$g(\mu) = X\beta$$

Logistični model

- Za računanje verjetnosti iz binarnih podatkov, predpostavimo model oblike

$$\text{logit}(p) = \log \left(\frac{p}{1-p} \right) = X\beta$$


Logistični model

- Za računanje verjetnosti iz binarnih podatkov, predpostavimo model oblike

$$\text{logit}(p) = \log\left(\frac{p}{1-p}\right) = X\beta$$

- Izrazimo

$$p_i = \frac{\exp(x_i^\top \beta)}{1 + \exp(x_i^\top \beta)}$$



Logistični model

- Za računanje verjetnosti iz binarnih podatkov, predpostavimo model oblike

$$\text{logit}(p) = \log \left(\frac{p}{1-p} \right) = X\beta$$

- Izrazimo

$$p_i = \frac{\exp(x_i^\top \beta)}{1 + \exp(x_i^\top \beta)}$$

- Izračunamo še prvi in drugi odvod logaritemske funkcije verjetja

Metoda največjega verjetja

- Najprej privzemimo gostote oblike $f_X(x; \theta) = f(x; \theta_1, \dots, \theta_r)$ za nek $\theta \in \Theta^r$
- Pri fiksni realizaciji poskusa definiramo *funkcijo verjetja*

$$F(X_1, \dots, X_n; \underbrace{\theta_1, \dots, \theta_r}_{\theta}) = f(X_1, \theta) \cdots f(X_n, \theta)$$

Metoda največjega verjetja

- Najprej privzemimo gostote oblike $f_X(x; \theta) = f(x; \theta_1, \dots, \theta_r)$ za nek $\theta \in \Theta^r$
- Pri fiksni realizaciji poskusa definiramo *funkcijo verjetja*

$$F(X_1, \dots, X_n; \underbrace{\theta_1, \dots, \theta_r}_{\theta}) = f(X_1, \theta) \cdots f(X_n, \theta)$$

- Iščemo njen maksimum - to bo hkrati tudi maksimum $\log(F)$
- Sistemu

$$\frac{\partial}{\partial \theta_j} \log F(X, \theta) = 0, \quad j = 1, \dots, r$$

pravimo sistem enačb verjetja, njegova rešitev je *cenilka največjega verjetja*

Metoda največjega verjetja

- Najprej privzemimo gostote oblike $f_X(x; \theta) = f(x; \theta_1, \dots, \theta_r)$ za nek $\theta \in \Theta^r$
- Pri fiksni realizaciji poskusa definiramo *funkcijo verjetja*

$$F(X_1, \dots, X_n; \underbrace{\theta_1, \dots, \theta_r}_{\theta}) = f(X_1, \theta) \cdots f(X_n, \theta)$$

- Iščemo njen maksimum - to bo hkrati tudi maksimum $\log(F)$
- Sistemu

$$\frac{\partial}{\partial \theta_j} \log F(X, \theta) = 0, \quad j = 1, \dots, r$$

pravimo sistem enačb verjetja, njegova rešitev je *cenilka največjega verjetja*

- Niso nujno nepristranske, so pa dosledne, če je rešitev enolična
- **Običajno niso eksplicitno rešljive**

- Iterativne metode, ki temeljijo na Newtonovi metodi za iskanje ničel funkcije

$$x_{i+1} = x_i - \frac{f(x_i)}{f'(x_i)}$$

- Iterativne metode, ki temeljijo na Newtonovi metodi za iskanje ničel funkcije

$$x_{i+1} = x_i - \frac{f(x_i)}{f'(x_i)}$$

- Za iskanje ekstremov logaritemske funkcije verjetja $\ell(\theta)$ enačimo njen gradient z nič in dobimo

$$\theta_{i+1} = \theta_i - \frac{\frac{\partial}{\partial \theta} \ell(\theta)}{\frac{\partial^2}{\partial \theta^2} \ell(\theta)},$$

računanje in invertiranje Hessiana pa je lahko problematično. Kako se lahko temu izognemo?

Fisherjeva zbirna metoda

$$\theta_{i+1} = \theta_i + \text{FI}(\theta)^{-1} \left(\frac{\partial}{\partial \theta} \ell \right),$$

kjer je $\text{FI}(\theta) = \mathbb{E} \left(\left(\frac{\partial}{\partial \theta} \ell \right) \left(\frac{\partial}{\partial \theta} \ell \right)^\top \right)$

Fisherjeva zbirna metoda

$$\theta_{i+1} = \theta_i + \text{FI}(\theta)^{-1} \left(\frac{\partial}{\partial \theta} \ell \right),$$

kjer je $\text{FI}(\theta) = \mathbb{E} \left(\left(\frac{\partial}{\partial \theta} \ell \right) \left(\frac{\partial}{\partial \theta} \ell \right)^\top \right)$ Informacijska enakost pravi

$$\text{FI}(\theta) = \mathbb{E} \left(\left(\frac{\partial}{\partial \theta} \ell \right) \left(\frac{\partial}{\partial \theta} \ell \right)^\top \right) = -\mathbb{E} \left(\frac{\partial^2}{\partial \theta^2} \ell \right),$$

Fisherjeva zbirna metoda

$$\theta_{i+1} = \theta_i + \text{FI}(\theta)^{-1} \left(\frac{\partial}{\partial \theta} \ell \right),$$

kjer je $\text{FI}(\theta) = \mathbb{E} \left(\left(\frac{\partial}{\partial \theta} \ell \right) \left(\frac{\partial}{\partial \theta} \ell \right)^\top \right)$ Informacijska enakost pravi

$$\text{FI}(\theta) = \mathbb{E} \left(\left(\frac{\partial}{\partial \theta} \ell \right) \left(\frac{\partial}{\partial \theta} \ell \right)^\top \right) = -\mathbb{E} \left(\frac{\partial^2}{\partial \theta^2} \ell \right),$$

Za kanonične povezovalne smo dokazali

$$\mathbb{E} \left(\frac{\partial^2}{\partial \theta^2} \ell \right) = \frac{\partial^2}{\partial \theta^2} \ell$$

in sledi

$$\text{FI}(\theta) = -\frac{\partial^2}{\partial \theta^2} \ell$$

Fisherjeva zbirna metoda

$$\theta_{i+1} = \theta_i + \text{FI}(\theta)^{-1} \left(\frac{\partial}{\partial \theta} \ell \right),$$

kjer je $\text{FI}(\theta) = \mathbb{E} \left(\left(\frac{\partial}{\partial \theta} \ell \right) \left(\frac{\partial}{\partial \theta} \ell \right)^\top \right)$ Informacijska enakost pravi

$$\text{FI}(\theta) = \mathbb{E} \left(\left(\frac{\partial}{\partial \theta} \ell \right) \left(\frac{\partial}{\partial \theta} \ell \right)^\top \right) = -\mathbb{E} \left(\frac{\partial^2}{\partial \theta^2} \ell \right),$$

Za kanonične povezovalne smo dokazali

$$\mathbb{E} \left(\frac{\partial^2}{\partial \theta^2} \ell \right) = \frac{\partial^2}{\partial \theta^2} \ell$$

in sledi

$$\text{FI}(\theta) = -\frac{\partial^2}{\partial \theta^2} \ell$$

→ za kanonične povezovalne funkcije Fisherjeva zbirna metoda in Newtonov algoritem sovpadata!

Fisherjeva zbirna metoda

Taylorjev polinom za funkcijo zbira (ob upoštevanju $\ell(\theta^*) = 0$) je

$$\ell(\theta^* + s) = \ell(\theta^*) + \frac{1}{2} s^\top \frac{\partial^2}{\partial \theta^2} \ell(\theta^*) s.$$

Poleg tega pa velja še:

$$-\frac{\partial^2}{\partial \theta^2} \ell = \text{FI}(\theta) = \text{Var} \left(\frac{\partial}{\partial \theta} \ell \right)$$

Fisherjeva zbirna metoda

Taylorjev polinom za funkcijo zbira (ob upoštevanju $\ell(\theta^*) = 0$) je

$$\ell(\theta^* + s) = \ell(\theta^*) + \frac{1}{2} s^\top \frac{\partial^2}{\partial \theta^2} \ell(\theta^*) s.$$

Poleg tega pa velja še:


$$-\frac{\partial^2}{\partial \theta^2} \ell = \text{FI}(\theta) = \text{Var} \left(\frac{\partial}{\partial \theta} \ell \right)$$

torej je v θ^* maksimum in imamo konstanten (naraščajoč) alogirtem!

Rezultati

Iz interneta smo pridobili podatke o tesnilih iz vesoljskih poletov pred dobo *Challengerja* in izračunali:


- verjetnost odpovedi z logistično regresijo le s podatki o temperaturi



Rezultati

Iz interneta smo pridobili podatke o tesnilih iz vesoljskih poletov pred dobo *Challengerja* in izračunali:

- verjetnost odpovedi z logistično regresijo le s podatki o temperaturi
- verjetnost odpovedi s temperaturo in pritiskom



Rezultati

Iz interneta smo pridobili podatke o tesnilih iz vesoljskih poletov pred dobo *Challengerja* in izračunali:

- verjetnost odpovedi z logistično regresijo le s podatki o temperaturi
- verjetnost odpovedi s temperaturo in pritiskom
- primerjava logistične in probit regresije le s podatki o temperaturi

